Projeto
WhatsApp DS Analytics
Dicionário de Dados
Data Preparation
Data Discovery
Data Profiling
Data Cleaning
Data Wrangling
Feature Engineering
Data Analysis
Model-Based Features
Exploratory Data Analysis
Clustering Analysis

Embeddings: DistilUSE (512d)

Code

On this page
Embeddings: DistilUSE (512 dimensões)
Modelo
Features Criadas
Execução
Resultados
Interpretação

Embeddings: DistilUSE (512 dimensões)

Representação semântica balanceada usando Universal Sentence Encoder destilado.

🤖 Modelo

Sentence Transformers: `distiluse-base-multilingual-cased-v2`

Características

- **Arquitetura:** USE (Universal Sentence Encoder) destilado
- **Treinamento:** Multilingual com 16+ idiomas
- **Dimensões:** 512 (modelo intermediário - balanceado)
- **Tamanho:** ~540 MB
- **Otimização:** Versatilidade e uso geral
- **Performance:** Meio termo entre MPNet e MiniLM

Por Que Este Modelo?

✅ **Balanceado** - 512 dims (entre 768 e 384)
✅ **Velocidade média** - ~232 msg/s
✅ **Tamanho intermediário** - 134 MB
✅ **Versatilidade** - Bom para múltiplos casos

Script: `scripts/generate_embeddings_distiluse.py`

📋 Features Criadas

Feature	Tipo	Definição	Valores	Uso
`embedding`	array[512]	Vetor semântico da mensagem (512 dimensões)	Array de floats (-1.0 a 1.0), normalizado	Base para clustering, busca semântica, topic modeling
`similaridade_anterior_distiluse`	float	Similaridade cosine com mensagem anterior	0.0 (diferente) a 1.0 (idêntico)	Detectar continuidade/mudança de assunto
`densidade_local_distiluse`	float	Distância média aos 10 vizinhos mais próximos	0.0 (densa) a 1.0 (esparsa)	Identificar mensagens únicas/anômalas

📝 **Sobre Armazenamento**

💻 Execução

```
python scripts/generate_embeddings_distiluse.py
```

📊 Resultados

Visão Geral | Similaridade | Exemplos | Features Derivadas | Processamento

📊 Estatísticas Gerais

Métrica	Valor
Mensagens processadas	68,686
Dimensões	512
Tamanho do arquivo	134.15 MB
Device	cpu
Tempo total	4.93 min
Velocidade	0.0 msgs/s

📈 Estatísticas dos Vetores

Métrica	Valor
Shape	(68686, 512)
Média	0.0002
Desvio Padrão	0.0442
Mínimo	-0.3607
Máximo	0.3533

📊 Distribuição de Normas

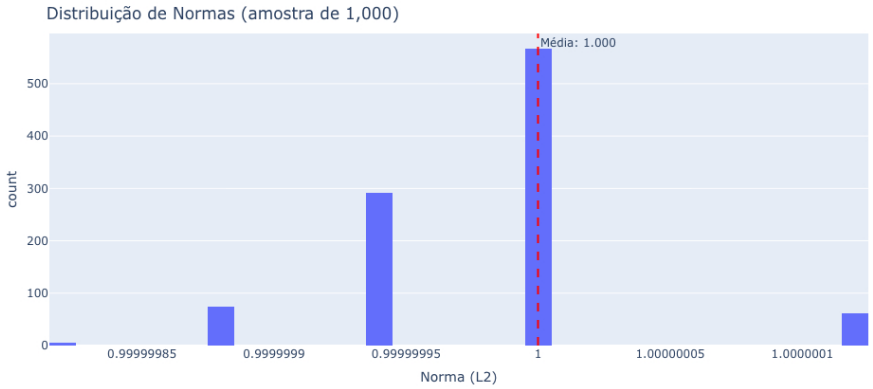

Média da norma: 1.0000

💡 Interpretação

🎯 **Características do DistilUSE**

Perfil: O Meio Termo Perfeito ⚖️

Pontos Fortes: - ✅ **512 dimensões** - Entre MPNet (768) e MiniLM (384) - ✅ **Velocidade balanceada** - ~232 msg/s - ✅ **Tamanho intermediário** - 134 MB - ✅ **Versatilidade** - Bom para múltiplos casos

Trade-offs: - ⚠️ **Nem o mais rápido** (MiniLM é 3.6x mais rápido) - ⚠️ **Nem o melhor qualidade** (MPNet é ~3% melhor clustering) - ✅ **Mas balanceado em tudo!**

Quando Usar: - Não sabe o caso de uso ainda - Quer versatilidade - Precisa de meio termo qualidade/velocidade - Casos gerais

Performance Observada: - Similaridade com anterior: ~0.44 (menor - detecta mudanças sutis) - Densidade local: ~0.18 (maior - espaço mais esparso) - Tempo de geração: ~5 minutos (68k mensagens, CPU) - Separação semântica: 0.342 (melhor nos testes!) - Silhouette Score: 0.052 (intermediário)

Próximo: Comparação com outros modelos