Projeto
WhatsApp DS Analytics
Dicionário de Dados
Data Preparation
Data Discovery
Data Profiling
Data Cleaning
Data Wrangling
Feature Engineering
Data Analysis
Model-Based Features
Exploratory Data Analysis
Clustering Analysis

Clustering Analysis

Code

Análise de clusters: features estruturais vs embeddings semânticos

AUTHOR
Marlon

PUBLISHED
December 6, 2025

On this page
Configuração
Introdução
1. Carregamento dos Dados
2. Clustering Estrutural (Features Derivadas)
5. Próximos Passos

Configuração

Dataset	Status	Uso
`messages_enriched.parquet`	✅ Disponível	Clustering Estrutural
`messages_with_models.parquet`	✅ Disponível	Clustering Semântico

```
⚡ Configurações de Performance:
```

Parâmetro	Valor
Amostra para Elbow/Silhouette	15,000
Batch size (MiniBatchKMeans)	1,024
Chunk size (processamento)	10,000

Introdução

Este notebook explora **duas abordagens de clustering** para identificar padrões nas conversas:

1. **Clustering Estrutural** — Usa features numéricas derivadas (temporais, texto, conversação)
2. **Clustering Semântico** — Usa embeddings de modelos de linguagem

A comparação entre as duas abordagens revela insights complementares: - Estrutural captura **comportamento** (quando, como, quanto) - Semântico captura **conteúdo** (o que, significado)

> ⓘ **Otimização de Memória**
> Este notebook usa **MiniBatchKMeans** e **amostragem estratificada** para processar grandes volumes de dados sem estourar memória.

1. Carregamento dos Dados

Métrica	Valor
Mensagens	91,924
Colunas	43
Período	19/10/2024 → 20/10/2025

2. Clustering Estrutural (Features Derivadas)

Agrupa mensagens usando features numéricas criadas no Feature Engineering.

2.1 Seleção de Features

Categoria	Feature	Status
Temporais	`hora`	✅
Temporais	`dia_semana_num`	✅
Temporais	`mes`	✅
Temporais	`fim_de_semana`	✅
Temporais	`horario_comercial`	✅
Texto	`tamanho_caracteres`	✅
Texto	`tamanho_palavras`	✅
Texto	`tem_emoji`	✅
Texto	`qtd_emojis`	✅
Texto	`tem_link`	✅
Texto	`tem_interrogacao`	✅
Texto	`tem_exclamacao`	✅
Texto	`eh_caixa_alta`	✅
Conversação	`tempo_desde_ultima_msg`	✅
Conversação	`eh_resposta_rapida`	✅
Conversação	`sequencia_mesmo_remetente`	✅
Conversação	`eh_inicio_conversa`	✅

Features disponíveis para clustering: 17

2.2 Determinação do Número de Clusters

```
📊 Usando amostra de 15,000 mensagens para determinar K ótimo
   (de 91,924 total - 16.3%)
```

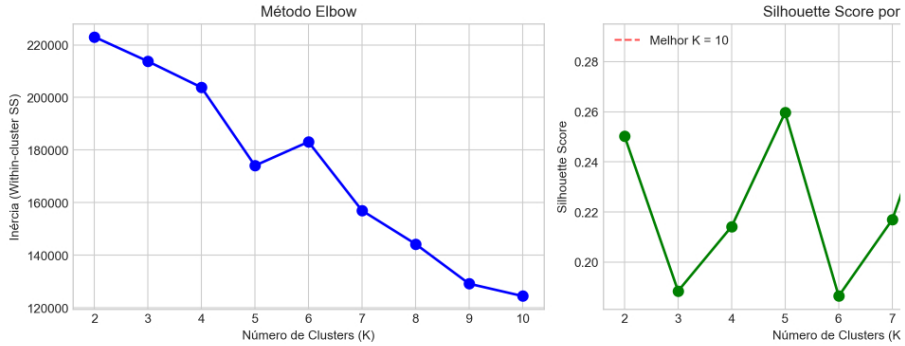

Método Elbow e Silhouette Score para determinar número ótimo de clusters

```
📊 Melhor K pelo Silhouette Score: 10
```

2.3 Clustering Final

Métrica	Valor
Número de Clusters	10
Silhouette Score (amostra)	0.277
Interpretação	Moderado

2.4 Distribuição dos Clusters

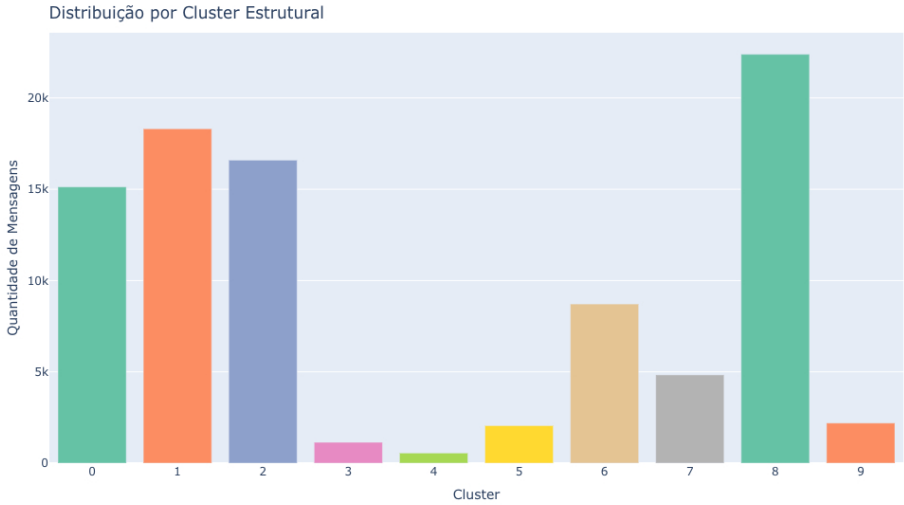

Distribuição de mensagens por cluster estrutural

2.5 Perfil dos Clusters

Perfil dos Clusters Estruturais (Features Normalizadas)

Feature								
hora	0.09	-0.70	0.94	-0.69	-0.09	0.04	-0.03	-0.14
mes	-1.21	0.63	0.44	-0.05	0.24	-0.38	0.18	0.06
fim_de_semana	-0.61	-0.61	-0.61	-0.08	0.18	-0.10	-0.61	-0.06
horario_comercial	0.33	1.13	-0.79	0.17	-0.13	0.06	0.45	0.18
tamanho_caracteres	-0.02	0.01	-0.05	0.03	1.03	-0.09	0.02	0.31
tamanho_palavras	-0.02	0.03	-0.05	0.03	0.04	-0.11	0.03	0.34
tem_emoji	0.11	0.01	-0.00	0.25	-0.13	-0.01	-0.08	-0.23
qtd_emojis	0.08	0.00	-0.01	0.20	-0.02	-0.01	-0.04	-0.09
tem_link	-0.08	-0.08	-0.08	-0.08	12.83	-0.08	-0.08	-0.08
tem_interrogacao	-0.24	-0.24	-0.24	-0.05	-0.24	-0.19	-0.24	4.21
tem_exclamacao	-0.16	-0.16	-0.16	0.26	-0.15	-0.14	-0.16	-0.16
eh_caixa_alta	-0.16	-0.16	-0.16	0.20	-0.16	6.37	-0.16	-0.16
tempo_desde_ultima_msg	-0.03	-0.04	-0.04	2.16	0.38	-0.03	0.01	-0.03
eh_resposta_rapida	0.22	0.48	0.48	-2.06	-0.76	0.06	-2.06	0.09
sequencia_mesmo_remetente	-0.32	0.16	0.30	-0.23	0.41	-0.19	-0.38	-0.05
eh_inicio_conversa	-0.12	-0.12	-0.12	8.67	0.90	-0.12	-0.12	-0.12

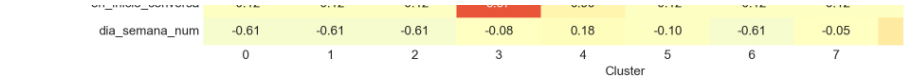

Perfil médio normalizado de cada cluster

```
📋 **Interpretação dos Clusters:**

**Cluster 0** (15,128 mensagens)
  📈 Características altas: horario_comercial, eh_resposta_rapida, tem_emoji
  📉 Características baixas: mes, fim_de_semana, dia_semana_num

**Cluster 1** (18,312 mensagens)
  📈 Características altas: horario_comercial, mes, eh_resposta_rapida
  📉 Características baixas: hora, fim_de_semana, dia_semana_num

**Cluster 2** (16,595 mensagens)
  📈 Características altas: hora, eh_resposta_rapida, mes
  📉 Características baixas: horario_comercial, fim_de_semana, dia_semana_num

**Cluster 3** (1,142 mensagens)
  📈 Características altas: eh_inicio_conversa, tempo_desde_ultima_msg, tem_exclamacao
  📉 Características baixas: eh_resposta_rapida, hora, sequencia_mesmo_remetente

**Cluster 4** (555 mensagens)
  📈 Características altas: tem_link, tamanho_caracteres, eh_inicio_conversa
  📉 Características baixas: eh_resposta_rapida, tem_interrogacao, eh_caixa_alta

**Cluster 5** (2,054 mensagens)
  📈 Características altas: eh_caixa_alta, horario_comercial, eh_resposta_rapida
  📉 Características baixas: mes, tem_interrogacao, sequencia_mesmo_remetente

**Cluster 6** (8,717 mensagens)
  📈 Características altas: horario_comercial, mes, tamanho_palavras
  📉 Características baixas: eh_resposta_rapida, fim_de_semana, dia_semana_num

**Cluster 7** (4,834 mensagens)
  📈 Características altas: tem_interrogacao, tamanho_palavras, tamanho_caracteres
  📉 Características baixas: tem_emoji, tem_exclamacao, eh_caixa_alta

**Cluster 8** (22,392 mensagens)
  📈 Características altas: dia_semana_num, fim_de_semana, mes
  📉 Características baixas: horario_comercial, tem_interrogacao, tem_exclamacao

**Cluster 9** (2,195 mensagens)
  📈 Características altas: tem_exclamacao, horario_comercial, mes
  📉 Características baixas: hora, tem_interrogacao, tem_emoji
```

2.6 Clusters por Participante

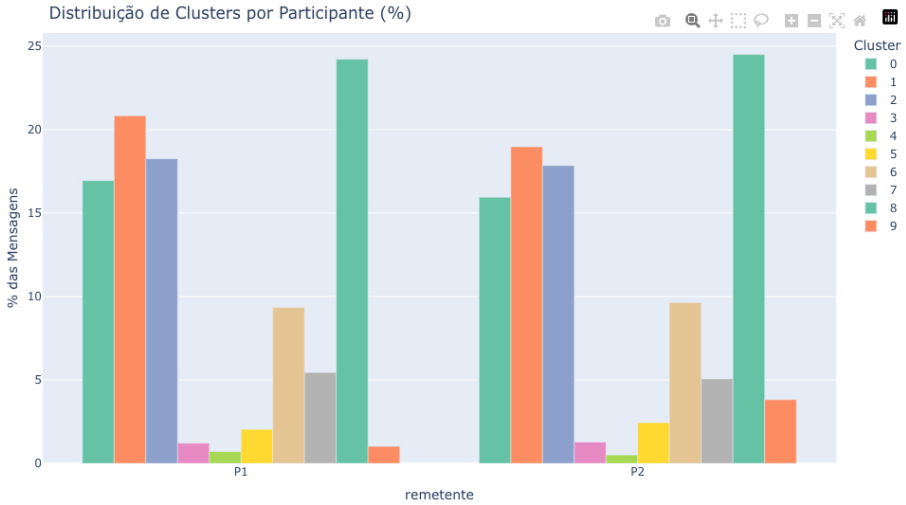

Distribuição de clusters por participante

2.7 Visualização 2D (PCA)

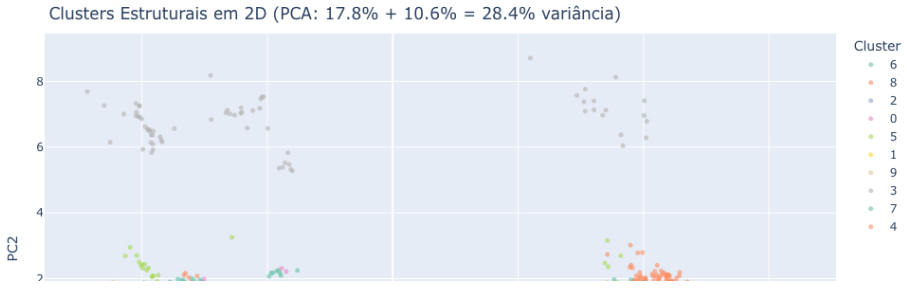

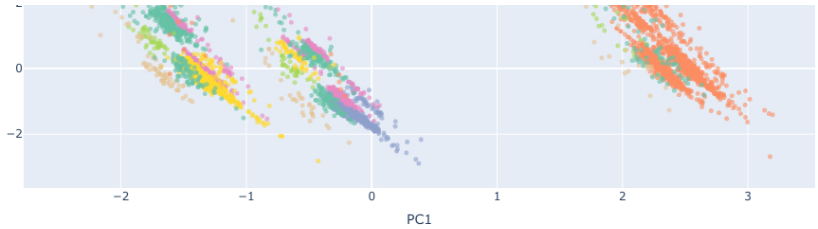

Projeção PCA dos clusters estruturais

---

5. Próximos Passos

Com os clusters identificados, as próximas análises podem incluir:

1. **EDA por Cluster** — Explorar características de cada grupo
2. **Análise Temporal** — Como os clusters evoluem ao longo do tempo
3. **Radar Charts** — Perfis visuais de P1 vs P2 por cluster
4. **MCA** — Análise de correspondência para variáveis categóricas

```
✅ **Análise de Clustering Concluída**

📦 Dataset salvo: messages_clustered.parquet
   Clusters estruturais: 10
```

Exportar Clusters

O dataset com clusters foi salvo em `messages_clustered.parquet`. Use-o nos próximos notebooks para análises segmentadas.